# 关联规则

# 目录

1 关联规则简介

2 Apriori算法

# 关联规则简介

“尿布与啤酒”的故事。

- 这是一个来自沃尔玛超市的真实案例，美国的沃尔玛超市对一年多的原始交易数据进行了详细的分析，得到一个意外发现：与尿布一起被购买最多的商品竟然是啤酒。

- 借助于数据仓库和关联规则，商家发现了这个隐藏在背后的事实：美国的妇女们经常会嘱咐她们的丈夫下班以后要为孩子买尿布，而30%～40%的丈夫在买完尿布之后又要顺便购买自己爱喝的啤酒。

# 关联规则简介

关联规则分析也称成为购物篮分析

这个购物篮中有橙汁、香蕉、洗洁精和玻璃清洁剂，以及6罐苏打水

商品的摆放位置对顾客的购买有影响吗？

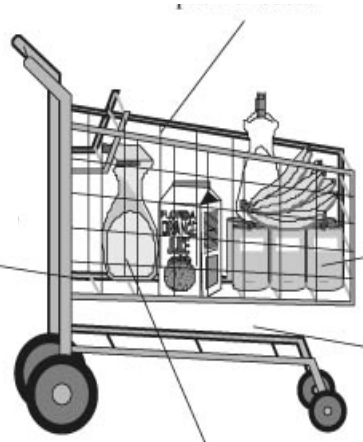

苏打水通常和香蕉一起被购买吗？不同的品牌有无区别

哪些商品应该出现而没有出现？

当同时购买洗洁精和橙汁时，玻璃清洁剂也常常同时够买吗？

# 关联规则简介

- 关联规则（Association Rules）是数据挖掘的概念，通过数据分析，找出数据之间的关联。反映一个事物与其他事物之间的相互依存性和关联性。
- 电商中经常用来分析购买物品之间的相关性，如，“购买尿布的用户，很大概率购买啤酒”。
- 如果把“购买尿布”的事件记作A，“购买啤酒”记作事件B，则上面规则可以写作“A→B”。

- 关联规则推荐是利用关联规则实施推荐，希望达到“将尿布放入购物篮后，再推荐啤酒”比“直接推荐啤酒”获得更好的售卖效果。（有些场景比直接推荐更有效）

# 关联规则简介

关联规则的实际探索与应用

1. 70%购买了牛奶的顾客将倾向于同时购买面包；
2. 某网店或某宝买了商品时，会向顾客推荐相关商品；
3. 在保险业务方面，如果出现了不常见的索赔要求组合，则可能为欺诈，需要作进一步的调查；
4. 在医疗方面，可以找出可能的治疗组合；
5. 在银行方面，对顾客进行分析，可以推荐感兴趣的服务等等。

# 目录

1 关联规则简介

2 Apriori算法

# Apriori算法

常用关联算法如下表：

| 算法名称 | 算法描述 |
| --- | --- |
| Apriori | 关联规则最常用也是最经典的挖掘频繁项集的算法，其核心思想是通过连接产生候选项及其支持度然后通过剪枝生成频繁项集。 |
| FP-Tree | 针对Apriori算法的固有的多次扫面事务数据集的缺陷，提出的不产生候选频繁项集的方法。Apriori和FP-Tree都是寻找频繁项集的算法。 |
| Eclat算法 | Eclat算法是一种深度优先算法，采用垂直数据表示形式，在概念格理论的基础上利用基于前缀的等价关系将搜索空间划分为较小的子空间。 |
| 灰色关联法 | 分析和确定各因素之间的影响程度或是若干个子因素（子序列）对主因素（母序列）的贡献度而进行的一种分析方法。 |

# Apriori算法

抽取某餐饮企业10个点餐订单，将菜品{18491，8842，8693，7794，8705}分别简记为{a，b，c，d，e}，订单数据如下所示：

| 订单号 | 菜品id | 菜品id |
|---|---|---|
| 1 | 18491, 8693，8705 | a，c，e |
| 2 | 8842,7794 | b，c，d |
| 3 | 8842，8693 | b，c |
| 4 | 18491，8842，8693，7794 | a，b，c，d |
| 5 | 18491，8842 | a，b，c |
| 6 | 8842，8693 | b，c |
| 7 | 18491，8842 | a，b，c |
| 8 | 18491，8842,8693,8705 | a，b，c，e |
| 9 | 18491，8842,8693 | a，b，c |
| 10 | 18491，8693 | a，c，e |

# Apriori算法

## 数据准备

- 纵坐标是10个订单数据（**事务**）
- 横坐标是每笔订单售出的商品（**项集**）
- 其中，{a，b，c，d，e}为**项**。

| | a | b | c | d | e |
|---|---|---|---|---|---|
| 1 | 1 | | 1 | | 1 |
| 2 | | 1 | 1 | 1 | |
| 3 | | 1 | 1 | | |
| 4 | 1 | 1 | 1 | 1 | |
| 5 | 1 | 1 | 1 | | |
| 6 | | 1 | 1 | | |
| 7 | 1 | 1 | 1 | | |
| 8 | 1 | 1 | 1 | | 1 |
| 9 | 1 | 1 | 1 | | |
| 10 | 1 | | 1 | | 1 |

# Apriori算法

事务和项集

关联规则的分析对象是事务( Transaction)。

1. 超市顾客的购买行为是一种事务
2. 网页用户的页面浏览行为是一种事务
3. 一份保险公司的人寿保单也是一种事务

项集也即购物篮，在实际应用中有多种不同的理解

1. 将一个用户的一次网页浏览记录看作购物篮
2. 将一个用户的所有网页浏览记录看作购物篮

# Apriori算法

令$I=\{i1,i2,...,id\}$是购物篮数据中所有项的集合，而$T=\{t1,t2,...,tN\}$是所有事务的集合。

1. 每个事务ti包含的项集都是I的子集。
2. k-项集：一个包含k个项的项集
3. 事务的宽度定义为事务中出现的项的个数

# Apriori算法

关联规则和频繁项集

关联规则

- 形如 X→Y形式的蕴含表达式, 其中X和 Y是不相交的项集
- 例如: {牛奶, 尿布} →{啤酒}
- {牛奶, 尿布}称为规则的前件，而{啤酒} 为后件

可以列出很多关联规则，哪些规则是有意义的、具有应用价值?

# Apriori算法

关联规则和频繁项集

项集的重要性质是它的支持度计数(　)：一个项集出现的次数

({牛奶，面包，尿布}) = 2

关联规则的强度可以用它的支持度(Support)和置信度(Confidence)度量

规则评价方法

1. 支持度 (s)：包含X和Y的事务的几率
2. 置信度 (c)：包含X的事务中Y出现的几率（X出现的前提下Y的条件概率）

# Apriori算法

计算关联规则（组合商品）的支持度

- 共10笔订单，7笔包含菜品A，A的支持度为7/10。
- 支持度(Support)：评估菜品包含在订单的概率，即一个订单多大概率包含该菜品。

| | a | b | c | d | e |
|---|---|---|---|---|---|
| 1 | 1 | | 1 | | 1 |
| 2 | | 1 | 1 | 1 | |
| 3 | | 1 | 1 | | |
| 4 | 1 | 1 | 1 | 1 | |
| 5 | 1 | 1 | 1 | | |
| 6 | | 1 | 1 | | |
| 7 | 1 | 1 | 1 | | |
| 8 | 1 | 1 | 1 | | 1 |
| 9 | 1 | 1 | 1 | | |
| 10 | 1 | | 1 | | 1 |
| support | 7/10 | 8/10 | 10/10 | 2/10 | 3/10 |

# Apriori算法

## 计算关联规则（组合商品）的支持度

- 组合商品也可以计算支持度，如菜品A和菜品B同时包含在订单的概率。
- 一共有5个菜品，假设关联规则只关联2种菜品，则一共要计算多少个组合商品支持度?
- 一般会优先推荐支持度高的商品，如果推荐支持度低的商品，即使推荐效果翻倍，总体订单提升效果也会很有限。

| | a | b | c | d | e |
|---|---|---|---|---|---|
| 1 | 1 | | 1 | | 1 |
| 2 | | 1 | 1 | 1 | |
| 3 | | 1 | 1 | | |
| 4 | 1 | 1 | 1 | 1 | |
| 5 | 1 | 1 | 1 | | |
| 6 | | 1 | 1 | | |
| 7 | 1 | 1 | 1 | | |
| 8 | 1 | 1 | 1 | | 1 |
| 9 | 1 | 1 | 1 | | |
| 10 | 1 | | 1 | | 1 |
| support | 7/10 | 8/10 | 10/10 | 2/10 | 3/10 |
| support（A->B） | 5/10 | | | | |

# Apriori算法

## 计算关联规则（组合商品）的置信度

- 已知购买了A，多大概率购买了B（即同时购买了AB），称A->B的置信度。
- 购买A菜品的订单有7个，而7个订单中有5个订单包含菜品B，所以A->B的置信度为5/7。

- $confidence(A \rightarrow B) = \frac{support(A \rightarrow B)}{support(A)}$
- 本质是条件概率。
- 注意confidence（A->B）与confidence（B->A）不一定相等。

| | a | b | c | d | e |
|---|---|---|---|---|---|
| 1 | 1 | | 1 | | 1 |
| 2 | | 1 | 1 | 1 | |
| 3 | | 1 | 1 | | |
| 4 | 1 | 1 | 1 | 1 | |
| 5 | 1 | 1 | 1 | | |
| 6 | | 1 | 1 | | |
| 7 | 1 | 1 | 1 | | |
| 8 | 1 | 1 | 1 | | 1 |
| 9 | 1 | 1 | 1 | | |
| 10 | 1 | | 1 | | 1 |
| support | 7/10 | 8/10 | 10/10 | 2/10 | 3/10 |
| support（A->B） | 5/10 | | | | |
| confidence（A->B） | 5/7 | | | | |

# Apriori算法

计算关联规则（组合商品）的提升度

- confidence（E->C）= 1，即购买了菜品E的用户100%购买C，那么是不是意味着，如果用户将菜品E加入购物篮就可以向用户推荐菜品A?
- 虽然购买E之后100%购买C，但是直接购买C的支持度也是100%，购买C和购买E是独立事件。这里的关联规则推荐并没有比直接推荐获取更好的效果。
- 评估关联规则效果：提升度

| | a | b | c | d | e |
|---|---|---|---|---|---|
| 1 | 1 | | 1 | | 1 |
| 2 | | 1 | 1 | 1 | |
| 3 | | 1 | 1 | | |
| 4 | 1 | 1 | 1 | 1 | |
| 5 | 1 | 1 | 1 | | |
| 6 | | 1 | 1 | | |
| 7 | 1 | 1 | 1 | | |
| 8 | 1 | 1 | 1 | | 1 |
| 9 | 1 | 1 | 1 | | |
| 10 | 1 | | 1 | | 1 |
| support | 7/10 | 8/10 | 10/10 | 2/10 | 3/10 |
| support（A->B） | 5/10 | | | | |
| confidence（A->B） | 5/7 | | | | |

# Apriori算法

计算关联规则（组合商品）的提升度

- 提升度lift：用A->B的置信度与直接推荐B的支持度的比值用来评估推荐效果

  。$lift(A \rightarrow B) = \frac{confidence(A \rightarrow B)}{support(B)}$

- 大于1，说明有效，在购买A时推荐B比直接推荐B效果更好；
- 等于1，说明无关，购买A与购买B是独立事件；
- 小于1，说明负相关，购买A时推荐B，效果不如直接推荐B

| | a | b | c | d | e |
|---|---|---|---|---|---|
| 1 | 1 | | 1 | | 1 |
| 2 | | 1 | 1 | 1 | |
| 3 | | 1 | 1 | | |
| 4 | 1 | 1 | 1 | 1 | |
| 5 | 1 | 1 | 1 | | |
| 6 | | 1 | 1 | | |
| 7 | 1 | 1 | 1 | | |
| 8 | 1 | 1 | 1 | | 1 |
| 9 | 1 | 1 | 1 | | |
| 10 | 1 | | 1 | | 1 |
| support | 7/10 | 8/10 | 10/10 | 2/10 | 3/10 |
| support（A->B） | 5/10 | | | | |
| confidence（A->B） | 5/7 | | | | |

# Apriori算法

计算关联规则（组合商品）的提升度

- 比较关联规则A->B与直接推荐B，效果有没有提升：
- 有7个订单购买A，而这7个订单中有5个购买了B，所以A->B的置信度为5/7，即购买A之后有5/7的概率购买B；
- 直接推荐B的话，10个订单有8个购买了B，所以B的支持度为8/10，即有8/10的概率直接购买B。
- 提升度小于1，所以在A->B关联推荐的效果不如直接推荐B。

| | a | b | c | d | e |
|---|---|---|---|---|---|
| 1 | 1 | | 1 | | 1 |
| 2 | | 1 | 1 | 1 | |
| 3 | | 1 | 1 | | |
| 4 | 1 | 1 | 1 | 1 | |
| 5 | 1 | 1 | 1 | | |
| 6 | | 1 | 1 | | |
| 7 | 1 | 1 | 1 | | |
| 8 | 1 | 1 | 1 | | 1 |
| 9 | 1 | 1 | 1 | | |
| 10 | 1 | | 1 | | 1 |
| support | 7/10 | 8/10 | 10/10 | 2/10 | 3/10 |
| support（A->B） | 5/10 | | | | |
| confidence（A->B） | 5/7 | | | | |

# Apriori算法

## 最小支持度和最小置信度

- 支持度大于最小支持度的项集称为频繁项集，如频繁3项集
- 最小置信度是用户或专家定义的衡量置信度的一个阈值，表示关联规则的最低可靠性。
- 对于给定的规则X→Y，置信度越高，Y包含在X的事物中出现的可能性就越大
- 同时满足最小支持度阈值和最小置信度阈值的规则称作强规则。

# Apriori算法

将关联规则挖掘任务分解为如下两个主要子任务:

1、频繁项集的产生

- 发现满足最小支持度阈值的所有项集，这些项集称作频繁项集

2、规则的产生

- 从上一步发现的频繁项集中提取所有高置信度的规则，这些规则称为强规则

频繁项集的产生是一个计算量巨大的工作

# Apriori算法

组合爆炸

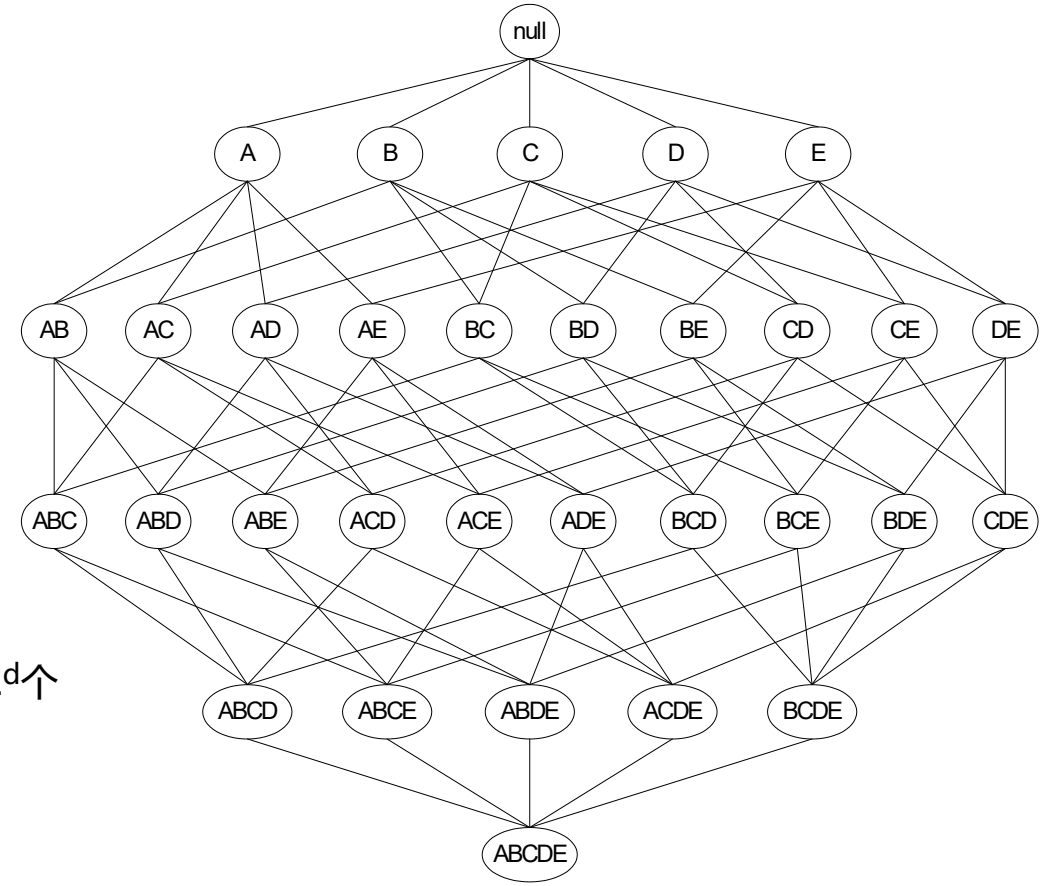


如果有d 项,则有 $2^d$个可能的候选项

# Apriori算法

先验原理

1. 如果一个项集是频繁的，则它的所有子集一定也是频繁的
2. 若项集{a,b}是非频繁的，则其所有超集也一定是非频繁的

一旦发现{a,b}是非频繁的，则整个包含{a,b}超集的子图可以被立即剪枝，这种基于支持度度量修剪指数搜索空间的策略称为基于支持度的剪枝

# Apriori算法

先验原理

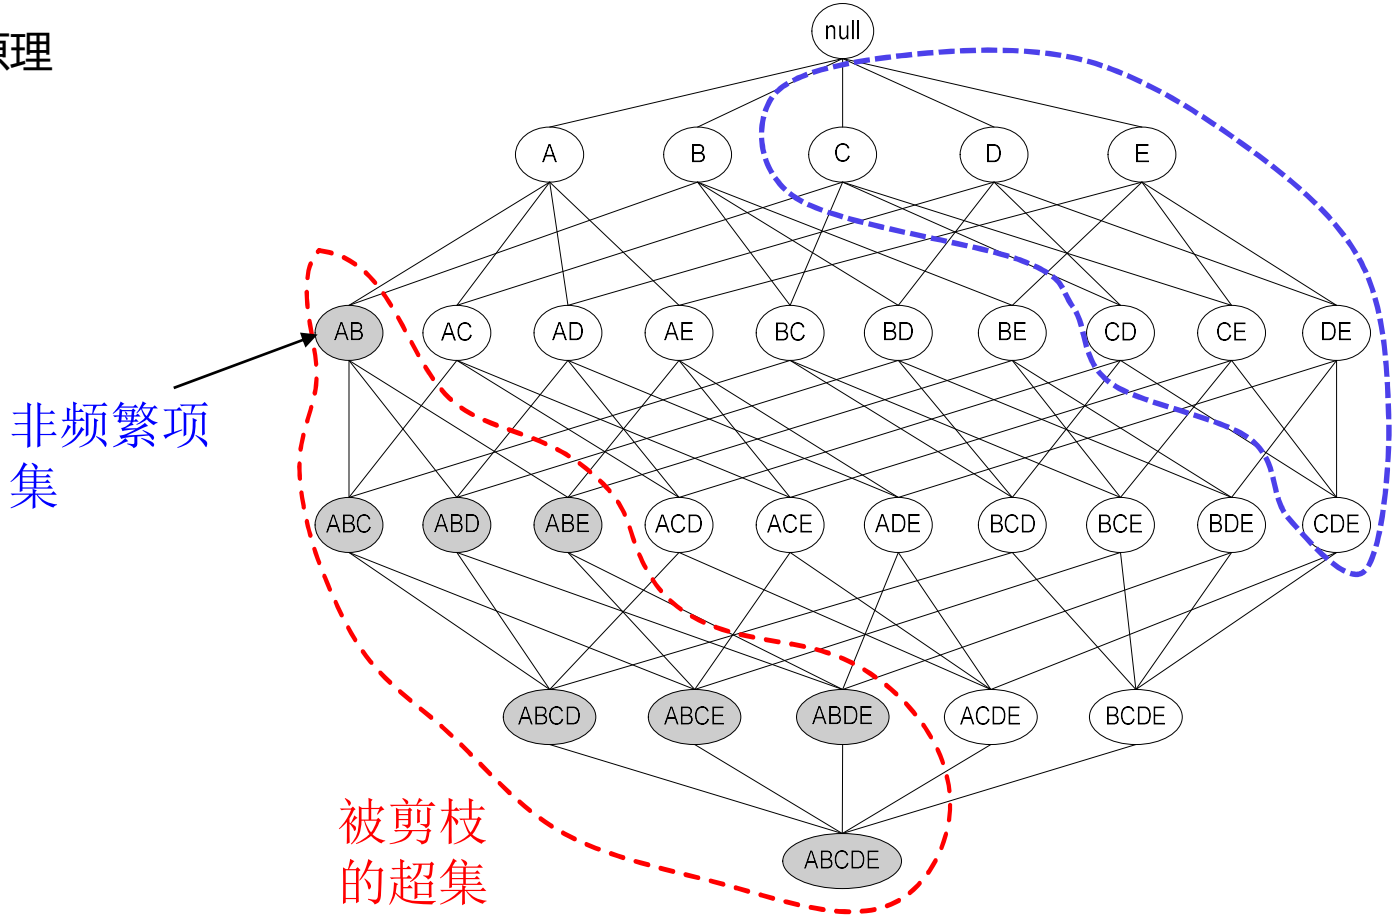

# Apriori算法

1. 通过单遍扫描数据集，确定每个项的支持度。得到频繁-1项集的集合F1
2. 使用上一次迭代发现的频繁(k-1)-项集，产生候选k-项集
3. 为了对候选项集的支持度计数，算法需要再次扫描一遍数据集。
4. 计算候选项的支持度计数后，删去支持度计数小于minsup的所有候选项集。
5. 当没有新的频繁项集产生时，算法结束。

# Apriori算法

首先将事务数据整理成关联规则模型所需的数据结构

抽取10个点餐订单作为事务数据集,将菜品{18491，8842，8693，7794，8705}分别简记为{a，b，c，d，e}

| 订单号 | 菜品id | 菜品id |
|---|---|---|
| 1 | 18491, 8693，8705 | a，c，e |
| 2 | 8842,7794 | b，d |
| 3 | 8842，8693 | b，c |
| 4 | 18491，8842，8693，7794 | a，b，c，d |
| 5 | 18491，8842 | a，b |
| 6 | 8842，8693 | b，c |
| 7 | 18491，8842 | a，b |
| 8 | 18491，8842,8693,8705 | a，b，c，e |
| 9 | 18491，8842,8693 | a，b，c |
| 10 | 18491，8693 | a，c，e |

| | a | b | c | d | e |
|---|---|---|---|---|---|
| 1 | 1 | | 1 | | 1 |
| 2 | | 1 | | 1 | |
| 3 | | 1 | 1 | | |
| 4 | 1 | 1 | 1 | 1 | |
| 5 | 1 | 1 | | | |
| 6 | | 1 | 1 | | |
| 7 | 1 | 1 | | | |
| 8 | 1 | 1 | 1 | | 1 |
| 9 | 1 | 1 | 1 | | |
| 10 | 1 | | 1 | | 1 |

# Apriori算法

设支持度为0.2，即支持度计数为2，算法过程如下图：

扫描事物集 → 得到每个候选项的支持度

$C_1$

| 项集 | 支持度 |
|---|---|
| {a} | 0.7 |
| {b} | 0.8 |
| {c} | 0.7 |
| {d} | 0.2 |
| {e} | 0.3 |

比较候选支持度 → 与最小支持度得1项频繁集

$L_1$

| 1项频繁集 | 支持度 |
|---|---|
| {a} | 0.7 |
| {b} | 0.8 |
| {c} | 0.7 |
| {d} | 0.2 |
| {e} | 0.3 |

由 $L_1$ 产生候选 $C_2$ → 并计算支持度

$C_2$

| 项集 | 支持度 |
|---|---|
| {a, b} | 0.5 |
| {a, c} | 0.5 |
| {a, d} | 0.1 |
| {a, e} | 0.3 |
| {b, c} | 0.5 |
| {b, d} | 0.2 |
| {b, e} | 0.1 |
| {c, d} | 0.1 |
| {c, e} | 0.3 |
| {d, e} | 0 |

比较候选支持度 → 与最小支持度得2项频繁集

$L_2$

| 2项频繁集 | 支持度 |
|---|---|
| {a, b} | 0.5 |
| {a, c} | 0.5 |
| {a, e} | 0.3 |
| {b, c} | 0.5 |
| {b, d} | 0.2 |
| {c, e} | 0.3 |

由 $L_2$ 与 $L_1$ 连接 → 产生候选 $C_3$

$C_3$

| 项集 | 支持度 |
|---|---|
| {a, b, c} | 0.3 |
| {a, c, e} | 0.3 |

比较候选支持度 → 与最小支持度得3项频繁集

$L_3$

| 3项频繁集 | 支持度 |
|---|---|
| {a, b, c} | 0.3 |
| {a, c, e} | 0.3 |

# Apriori算法

运行程序的结果如下：

```
frozenset()  -->  frozenset({'a'})
支持度:  0.7 置信度:  0.7 提升度:  1.0
frozenset()  -->  frozenset({'b'})
支持度:  0.8 置信度:  0.8 提升度:  1.0
frozenset()  -->  frozenset({'c'})
支持度:  0.7 置信度:  0.7 提升度:  1.0
frozenset({'a'})  -->  frozenset({'c'})
支持度:  0.5 置信度:  0.7142857142857143 提升度:
1.0204081632653061
frozenset({'e'})  -->  frozenset({'a'})
支持度:  0.3 置信度:  1.0 提升度:  1.4285714285714286
frozenset({'d'})  -->  frozenset({'b'})
支持度:  0.2 置信度:  1.0 提升度:  1.25
frozenset({'e'})  -->  frozenset({'c'})
支持度:  0.3 置信度:  1.0 提升度:  1.4285714285714286
frozenset({'c', 'a'})  -->  frozenset({'e'})
支持度:  0.3 置信度:  0.6 提升度:  2.0
```

- 对输出结果进行解释：如关联规则“a---c 0.5　0.714286”这条，关联规则a---c的支持度support=0.5，置信度confidence=0.714286。对于餐饮业来说，这条规则意味着客户同时点菜品a和b的概率是50%，点了菜品a，再点菜品b的概率是71.4286%。知道了这些，就可以对顾客进行智能推荐，增加销量同时满足客户需求。

大数据成就未来

# Thank you!

泰迪科技：www.tipdm.com
热线电话：40068-40020